

Unity端侧推理引擎

从 NCNN 难以在 Unity 用同一套代码跨平台使用出发，
演进为面向五类业务的统一端侧推理引擎

多格式接入
统一引擎能力
五类应用方向

NCNN · ONNX /
Sentis · MNN

导入 · 编排 · 推理 · 验证
结果直接服务于业务应用

从 Unity 跨平台痛点，走向统一端侧推理引擎

起点

沉淀

推广

源于NCNN

成熟模型与数值基线
无法直接成为 Unity 内
跨平台复用的一套代码。

Unity 复刻

在 Unity 内承接模型语义
完成视觉 runner 的真实验证，
让结果能直接交给应用层。

统一推理引擎

NCNN、Sentis 与 MNN
作为模型来源接入，
共享统一 IR、能力与验证。

关键转变：从“某个 runner 能跑”升级为“多个来源的模型可复用、可验证、可推广”。

运行时统一推理引擎

现有工程已积累模型解析、算子实现和真实 runner 验证；端侧推理引擎负责把它们收敛为可交付的共同底座。

64 / 64

官方 ncnn Vulkan 层
完整复刻，具体ncnn完整功能

模型图可被识别与映射。

96

当前层注册入口总数。

覆盖 ncnn、PNNX
及 Sentis / ONNX 扩展。

5

随引擎附带的应用方向。

影像、教育、游戏、
医学、药学。

模型来源

统一 IR

能力验证

领域结果

产品定义：每一次模型接入，都能说明输入、输出、支持范围、验证证据与可消费的业务结果。

不同模型格式进入同一张图，输出统一的业务结果契约



领域包在引擎之上组合，业务规则不进入核心

影像AllImage | 医学 MONAI / VISTA | 游戏 AR | 教育 Vibe Coding | 药学 Docking

引擎交付的是一套可接入、可运行、可验证的通用框架

面向业务方的接口不暴露底层执行细节，而是保证模型可管理、结果可消费、问题可定位。

模型接入

NCNN / ONNX / Sentis / MNN 适配；
输入输出、标签、许可、性能档由
ModelManifest 管理。

图与算子

统一 IR、形状推导、算子库、编排与资源
生命周期，避免每个 runner 重写底层能力。

结果契约

分类、检测框、关键点、掩码、增强图像、
3D label volume 与候选排名均有明确输
出定义。

精度与量化

以任务目标选择 FP32、FP16 与权重量化；
把精度、内存和性能作为可登记能力。

验证与诊断

golden、数值误差、任务指标、性能记录
与失败节点定位，形成每次模型发布的证
据链。

领域适配

医学、教育、游戏与药学只定义业务输入
输出；通用推理能力由核心引擎一次实现、
持续复用。

统一推理会话

模型、输入、输出与版本
统一由 Manifest 描述。

调用方提交数据并获得
异步结果或可直接使用的
分类、框、掩码、图像、
体数据与候选排序。

发布证据：
能力报告 + 回归结果

源于 NCNN，覆盖 Sentis 与 MNN 的模型接入生态

格式决定模型从哪里来；统一 IR 和能力报告决定它是否能以可验证方式进入端侧产品。

ncnn

起源与首个成熟模型来源

已有模型、算子和 runner
验证资产可持续复用。

ONNX / Sentis

面向 Unity 与通用模型生态

把图结构、形状与常见视觉
算子统一映射到内部 IR。

MNN

面向移动端模型和量化生态

通过适配或离线转换
接入同一引擎能力面。

Canonical IR + ModelManifest + Capability Report

导入时即说明模型节点、输入输出、精度档、验证状态与受限能力，避免在应用现场才发现不可用。

算子能力围绕模型可接入与应用可交付组织

导入 + 形状 + 精度 + 契约 + 性能 + 回归 + 诊断

支持说明以实际模型与任务验证为准，不以注册数量替代可用结论。

通用视觉与基础计算

卷积、深度卷积、反卷积、激活、归一化、池化、逐点计算、图像转换和常见布局变换，支撑图像增强、检测与分割。

矩阵计算与 Transformer 主干

Gemm、InnerProduct、MatMul、Softmax、LayerNorm、Reduction、Attention 等能力面，支撑 CLIP、多模态、生成式与语言模型演进。

图编排与领域增长点

动态形状、索引选择、采样、检测后处理、KV cache 与 3D 体数据相关能力，决定 Sentis、AR、医学和本地语言模型的接入上限。

当前已支持的层算子，按功能分类完整列示

功能分类	已支持层算子
卷积与空间	Convolution · Convolution1D · Convolution3D · Deconvolution · Deconvolution3D Pooling · Pooling3D · Interp · PixelShuffle · Reorg · Unfold · Padding · Crop
线性、归一化与归约	Gemm · InnerProduct · MatMul · BatchNorm · GroupNorm · LayerNorm · PReLU ReLU · Softmax · ArgMax · ArgMin · TopK · CumSum · Scale
逐元素与激活	AbsVal · BinaryOp · Clip · Eltwise · GELU · Sigmoid · Swish · UnaryOp
张量形状与数据转换	Cast · Concat · Expand · ExpandDims · Flatten · Packing Permute · Reshape · Slice · Tile · Dequantize · Quantize Requantize · Shape · Size · ConstantOfShape · Range
索引、选择与生成	Gather · GatherElements · OneHot · Where

同一套引擎能力，面向五种不同的产品价值

Allimage 提供真实视觉验证；医学、教育、游戏与药学以各自的业务输入输出消费同一引擎。



引擎不复制业务规则：它把模型接入、算子、验证与资源管理沉淀一次，让每个应用专注于用户结果。

CLIP: 把图片变成可用于检索与分流的语义标签



输入: 03.jpg (600 x 337)

Top-1 输出: Photo, 置信度 0.873903

同一张图片与预设文本标签计算相似度, 得到可直接供素材检索、自动归档、内容路由或审核辅助使用的类别结果。

本次静默跑测: 模型 mobileclip_s0_export

Top-2 / Top-3

Portrait 0.099077
Night 0.013508

可实现的产品能力

图片语义分类、相似内容分流、素材检索入口与按标签触发的后续编辑链路。

输出不只是 embedding: runner 已将 embedding 与标签集转换成可读、可用的分类结果。

Model reference: MobileCLIP S0 | <https://github.com/apple/ml-mobileclip> ; deployment artifacts: exported ncnn image_encoder / text_encoder / projection_layer .param + .bin (ref/ncnn_mobileclip-main).

Yolo & SD Inpainting 去人 & 填充

——检测、掩码与局部重绘形成完整闭环




输入: 03.jpg; 右下: 人像掩码与最终输出

YOLO 检出 2 个人像，输出可直接驱动重绘的掩码

YOLO v8对原图完成实例级人像分割；掩码既可用于抠图，也可传给局部重绘模型。静默跑测中，固定 seed=123456，12 步完成去人流程。

最终输出展示了sd inpainting 1.5在推理引擎中被选区域已被背景内容替换，形成完整结果背景



输入图片 -> 人像掩码 -> 局部重绘输出：同一条工作流可服务内容清理、主体替换与设计编辑。

Model reference: Stable Diffusion v1.5 <https://github.com/CompVis/stable-diffusion> ; Inpainting weights <https://huggingface.co/runwayml/stable-diffusion-inpainting> ; deployment artifacts: exported ONNX / ncnn .param + .bin.

CodeFormer: 从模糊人脸中恢复更清晰、可用的面部细节


定位人脸，再恢复细节并回贴到原图

runner 从 03.jpg 自动检出 1 个主要人脸，将区域归一化到 512 x 512 进行修复，并把结果回贴到整图。

右图是完整输出，下方是模型实际处理的人脸输入区域；整条流程可用于历史照片、低清截图和人像素材修复。



输入: 03.jpg (600 x 337)



修复结果

运行成功
elapsed = 18,606 ms
输出: 17_full_output.png

对用户而言，能力不是“跑了一个模型”，而是“模糊人脸可以自动定位、修复并回到原图”。

Model reference: CodeFormer <https://github.com/sczhou/CodeFormer>; GFPGAN <https://github.com/TencentARC/GFPGAN>; ncnn reference <https://github.com/FeiGeChuanShu/GFPGAN-ncnn>; deployment artifacts: .param + .bin.

RealESRGAN: 实时4x超分



输入: 03.jpg (600 x 337)

同一张 03.jpg 经过图像增强，得到新的可用图像

使用 realesrgan-x4plus-anime 模型执行图像增强。
右图为静默跑测实际输出，左图为原图


可用于实时超分，图像增强、二次创作前处理和低质量素材处理的独立能力，也可串接在人像修复之后。



增强类 runner 将图像作为输入，也将新的图像作为输出，便于直接接入编辑器、素材管线和后续视觉模型。

Model reference: Real-ESRGAN <https://github.com/xinntao/Real-ESRGAN> ; ncnn reference <https://github.com/nihui/realesrgan-ncnn-vulkan> ; current model: realesrgan-x4plus-anime (.param + .bin).

MONAI / VISTA: 3D 分割用于体渲染、切割和导航



WholeBrain

MRI 体数据 -> 脑室 labelmap
sliding-window 全量推理
run46 labelmap 对齐率 0.998750372


VISTA

CT / MRI + 类别提示 -> 多标签掩码
已建立 skull 分割 Python 基线与 Unity
对齐验证

医学能力以准确性、可重复、可审计和受控资源为第一约束，目标是本地端侧的可消费分割结果。

Model reference: MONAI (Apache-2.0) <https://github.com/Project-MONAI/MONAI> ; MONAI Model Zoo <https://github.com/Project-MONAI/model-zoo> ; WholeBrain UNEST / VISTA3D: model.pt -> ONNX -> ncnn .param + .bin.

MONAI / VISTA: 3D 分割用于体渲染、切割和导航



WholeBrain

MRI 体数据 -> 脑室 labelmap
sliding-window 全量推理
run46 labelmap 对齐率 0.998750372

VISTA


CT / MRI + 类别提示 -> 多标签掩码
已建立 skull 分割 Python 基线与 Unity
对齐验证

医学能力以准确性、可重复、可审计和受控资源为第一约束，目标是本地端侧的可消费分割结果。

Model reference: MONAI (Apache-2.0) <https://github.com/Project-MONAI/MONAI> ; MONAI Model Zoo <https://github.com/Project-MONAI/model-zoo> ; WholeBrain UNEST / VISTA3D: model.pt -> ONNX -> ncnn .param + .bin.

Vibe Coding：儿童自然语言编程

学习者用中文描述意图，系统给出候选教学指令和可读预览



25 条自然语言规则映射到现有 canonical op; 模型输出被视为不可信输入，安全性来自 schema 与确认流程。



AlCityRunner: AR城市跑酷

场景物体识别
单人 / 多人姿态关键点
手势识别与手部 landmark




把相机画面转成分类、姿态和手势等 AR 结果，游戏和 AR 业务直接消费可定位、可叠加、可追溯的推理结果

接入目标覆盖图像识别、人体 / 物体姿态与手势识别。调用方提交 AR Camera 图像及坐标元数据，按需接收分类、框、关键点、置信度和可用于叠加的结果。引擎负责模型与后处理；何时提交、何时消费、如何驱动玩法由 AlCityRunner 业务层决定。

目标是让视觉模型输出成为 AR 场景里的可靠输入，而不是把推理细节和帧调度耦合进游戏代码。

请求 ID、时间戳、模型版本、置信度、坐标空间、关键点 / 分类结果与可用于 overlay 的 GPU 结果句柄。

PharmaDockingMR: 分子候选筛选可追溯



用户能得到什么

蛋白结构到口袋 / 体素条件，再到候选生成、fingerprint 与规则筛选，最终得到带分数、索引和 schema 版本的候选排序。

引擎沉淀什么

统一 C# / HLSL 原子类型、键类型、电荷、坐标、体素 / 热力图、候选索引和 fingerprint 的结构化数据契约。

为什么必须可追溯

药物筛选的风险不只是数值偏差，更是索引、类型和数据源错位。每次结果需要保留候选链、规则和版本，才能复核与迭代。

药物方向先统一数据语义与候选索引链，再扩展领域模型；这样才能把计算结果可靠地映射回正确的分子候选。

起源与与五大领域应用

推广的顺序不是简单扩大范围，而是先把可验证的通用能力做稳，再让新的模型生态和领域需求复用它。



路径清晰：源于NCNN，沉淀为覆盖ncnn/Sentis/MNN的通用端侧推理引擎，推广到五类应用方向。

END STATE

让端侧推理AI普惠

端侧推理引擎的价值，不在于累积更多单点 runner，而在于让每个模型来源、每次输出和每类业务结果都可复用、可验证、可推广。

持续扩展模型生态，
让NCNN、Sentis、MNN统一，影像/ 教育 / 游戏 / 医学 / 药学复用
同一通用端侧推理引擎底座。

AIIMAGE / UNITY INFERENCE ENGINE / 2026.07

多格式

NCNN / ONNX / Sentis / MNN
.bin / .onnx / pnnx

可验证

输入输出 / 指标 / 回归 / 诊断

可扩展

影像 / 教育 / 游戏 / 医学 / 药学

Acknowledgements & References

This demonstration references the following upstream frameworks, projects and pretrained models. Their original pages govern licenses, weights and data restrictions.

Inference framework & vision-language

ncnn (Tencent)
<https://github.com/Tencent/ncnn>

ONNX
<https://onnx.ai>

Unity Sentis
<https://github.com/Unity-Technologies/com.unity.sentis>

Image processing & generation

CodeFormer
<https://github.com/sczhou/CodeFormer>

GFPGAN / ncnn reference
<https://github.com/TencentARC/GFPGAN>
<https://github.com/FeiGeChuanShu/GFPGAN-ncnn>

Stable Diffusion / SD 1.5
<https://github.com/CompVis/stable-diffusion>

SD Inpainting
<https://huggingface.co/runwayml/stable-diffusion-inpainting>

Real-ESRGAN
<https://github.com/xinntao/Real-ESRGAN>
<https://github.com/nihui/realrgan-ncnn-vulkan>

MobileCLIP (Apple)
<https://github.com/apple/ml-mobileclip>

medical segmentation

MONAI / MONAI Model Zoo
<https://github.com/Project-MONAI/MONAI>
<https://github.com/Project-MONAI/model-zoo>

VISTA3D
<https://github.com/Project-MONAI/model-zoo/tree/dev/models/vista3d>

Format note: .onnx, .param and .bin shown in this deck are intermediate or deployment artifacts exported from upstream models. Conversion does not change ownership or redistribution terms.